

基于 EEG 的运动想象状态分类

曹斯淇

概述

本课题为 EEG 运动想象二分类问题。运动想象分类问题的难点在于：训练集规模小、个体差异大。因此笔者在基础模型上考虑采用迁移学习方法对目标域进行域适应。

首先，笔者选用了机器学习领域一些常见的基本模型：EEGNet、CNN、LSTM、CNN+LSTM、PCA+XGBoost 以及特征提取器（CSP、xDAWN）+分类器（LDA、SVM）的组合。模型的具体设置及选用理由将在第一小节介绍。

其次，针对本问题的难点，笔者尝试对基础模型进行一些改进，这些改进体现在第二小节中。本问题的难点在于小样本以及个体差异大，因此改进主要围绕迁移学习方法进行。笔者尝试的迁移学习方法分为两类，第一类是在训练模型前对数据分布进行修正，可以看作是预处理的方法，如 EA；第二类则是在训练模型的过程中进行域适应，如基于散度的域适应（MMD、CORAL、欧式距离）。此外基于对抗的域适应笔者也进行了尝试，但是由于其训练的不稳定性以及笔者有限的调参能力，我没有训练出一个可以使用的模型，故不在此赘述。

最后，在此简要地说明实验结果。基本模型中，只有 CNN 以及 CNN+LSTM 获得了较稳定的可用结果。其中，CNN 的准确率为 0.565，CNN+LSTM 准确率为 0.570。迁移学习部分分别以 CSP+LDA 和 CNN 作为 baseline，欧氏对齐方法以及基于散度的域适应方式都使模型性能提升。其中，EA+CSP+LDA 准确率达到了 0.630，EA+CNN+MMD 准确率同样达到了 0.630。更多的实验结果将在第三小节体现。

➤ 本报告分为四小节：

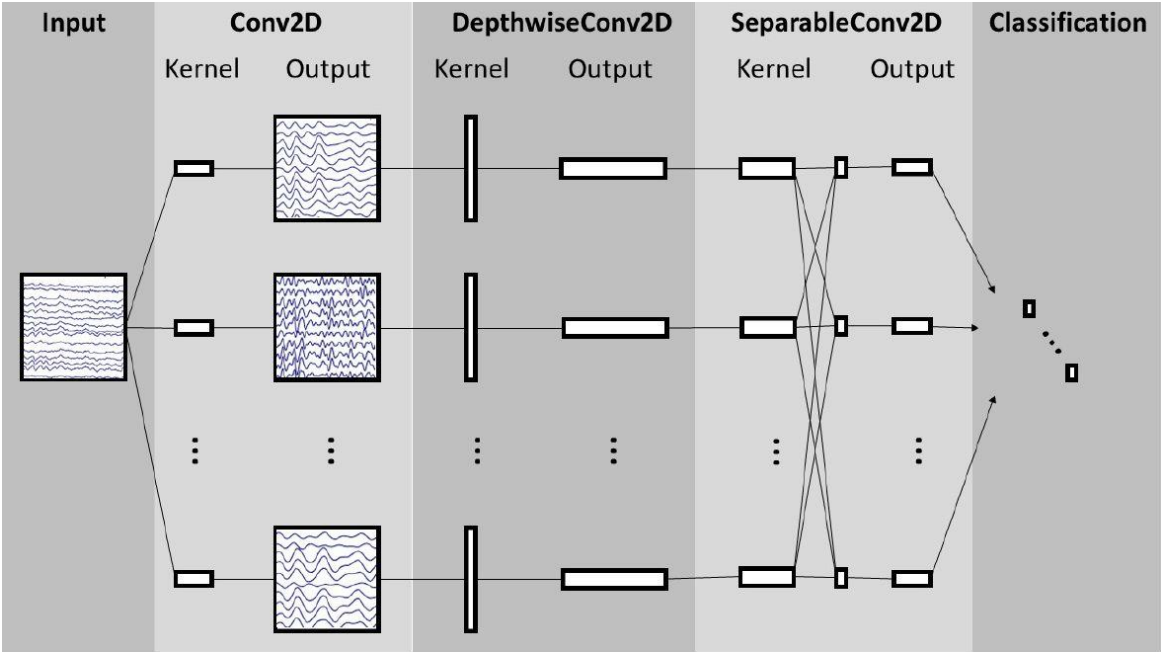
- 基础模型：本节介绍了选用的基础模型。
- 迁移学习：本小节介绍了迁移学习选用的具体方法及其与基本模型的结合方式。
- 实验：分别介绍基本模型以及迁移学习模型的实验结果。
- 结论

关键词 EEGNet, CNN, LSTM, PCA, XGBoost, CSP, xDAWN, 欧式对齐, 基于散度的域适应

1 基础模型

本节将对所采用基础模型进行介绍，包括选用理由及模型的具体参数等。

1.1 EEGNet



EEGNet 是专为处理 EEG 信号设计的网络。其优势在于(1)可以应用于几种不同的 BCI 范例(2)可以使用非常有限的数据进行训练，(3)可以产生神经生理学上可解释的特征。

EEGNet 模型如图和表所示，C 为导联数（64 为例）和 T 为时间点数（128 为例），模型包含了三个部分：Block1，Block2 和分类的 Block。

1.2 CNN

2D 卷积核相当于一个滤波器，在时间和空间维度上进行采样，提取局部特征。之后不断扩大感受野，逐渐融合成全局特征。

网络具体的设计参考 VGG 网络结构，设置了 3 个 VGG 模块和一个线性层。具体结构如下：

layer name	details
VGG block 1	conv3-16
	conv3-16
	batch norm
	Relu
	maxpool
VGG block 2	conv3-64

	conv3-64
	batch norm
	relu
	maxpool
VGG block 3	conv3-128
	conv3-128
	batch norm
	Relu
	maxpool
FC	FC-4736
	FC-128
	FC-2

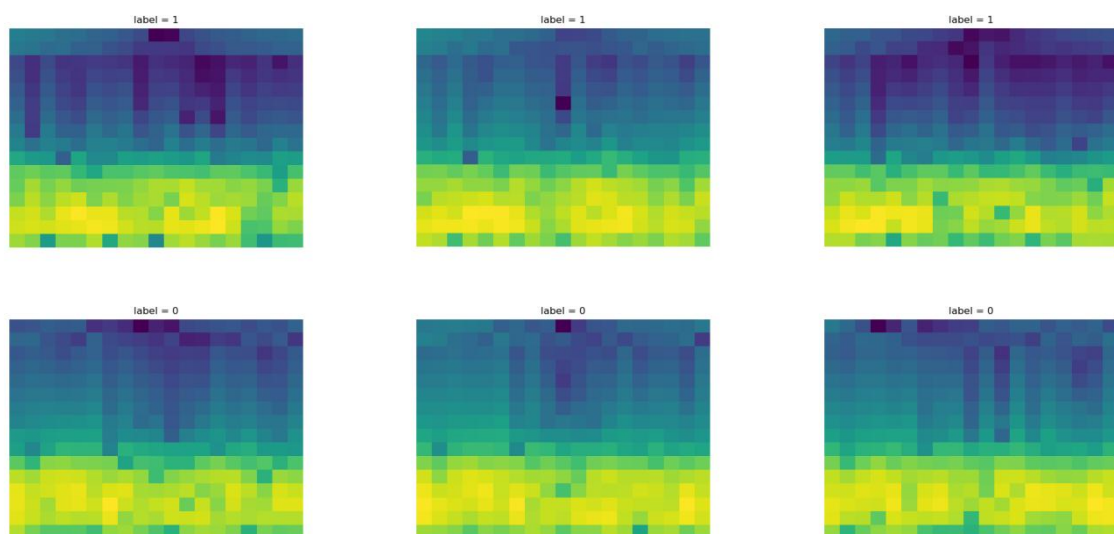
另外，经典的网络还有 ResNet 等，但因算力限制，无法构造比较深的网络，ResNet 的表现也就不是很明显。

1.2.1 以源数据作为输入

输入数据的形状为（trails, channels, samples），2D 卷积核在（channels, samples）平面上提取特征。

1.2.2 以时频图作为输入

每个 trail 的每个通道都是一个时间序列，可以对这个时域序列进行频域变换，并结合得到时频图（16, 19）。每个 trail 有 13 个通道，因此可得到 13 通道的时频图（13, 16, 19）。下图为部分单通道的时频伪彩图，分别对应于某个 trail 的某个通道。标签如图中标题所示，两种类别各含三张。



1.3 LSTM

由于源数据为时间序列，因此考虑使用 LSTM 网络。网络采用 5 层 LSTM 和一个线性分类层。

1.4 CNN+LSTM

在卷积网络的三个 block 后面加入 LSTM 层。CNN 的第三层输出形状为 $(b, 128, 1, 37)$ ，恰好可以看作是长度为 37，维度为 128 的时间序列。因此，把形状为 $(37, b, 128)$ 的序列输入 LSTM 层，获取时间信息。

1.5 PCA+XGBoost

将源数据 $(b, 13, 300)$ （经切割）展平成 $(b, 3900)$ 。考虑到 3900 维度过多，准备采用 PCA 对 3900 降维，之后再用 XGBoost 进行分类。

1.6 特征提取器+分类器

Wu 等人^[4]用 CSP 和 xDAWN 等空间滤波器，结合了 LDA 和 SVM 等分类器进行实验。因此本文也选择这两种组合。

CSP 是一种对两分类任务下的空域滤波特征提取算法，能够从多通道的脑机接口数据里面提取出每一类的空间分布成分。公共空间模式算法的基本原理是利用矩阵的对角化，找到一组最优空间滤波器进行投影，使得两类信号的方差值差异最大化，从而得到具有较高区分度的特征向量。查阅资料发现，通常来讲 CSP 尤其适合 EEG 运动想象任务分类。

2 迁移学习

本问题的难点在于小样本以及个体差异大，因此改进主要围绕迁移学习方法进行。笔者尝试的迁移学习方法分为两类，第一类是在训练模型前对数据分布进行修正，可以看作是预处理的方法，如 EA；第二类则是在训练模型的过程中进行域适应，如基于散度的域适应（MMD、CORAL、欧式距离）。此外基于对抗的域适应笔者也进行了尝试，但是由于其训练的不稳定性以及笔者有限的调参能力，我没有训练出一个可以使用的模型，故不在此赘述。

2.1 EA

He 等人^[2]提出使用欧式对齐方法对源域数据与目标域数据进行对齐。EA 算法旨在使对齐之后任意用户的 EEG 样本协方差矩阵的均值都为单位矩阵，整体分布更加一致。由于其无需知道数据标签，因而可用于本问题。EA 算法步骤如下图：

matrix \bar{R} , but estimated in a different way. Assume a subject has n trials. Then,

$$\bar{R} = \frac{1}{n} \sum_{i=1}^n X_i X_i^T, \quad (10)$$

i.e., \bar{R} is the arithmetic mean of all covariance matrices from a subject. We then perform the alignment by

$$\tilde{X}_i = \bar{R}^{-1/2} X_i. \quad (11)$$

After the alignment, the mean covariance matrix of all n aligned trials is:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^T &= \frac{1}{n} \sum_{i=1}^n \bar{R}^{-1/2} X_i X_i^T \bar{R}^{-1/2} \\ &= \bar{R}^{-1/2} \left(\frac{1}{n} \sum_{i=1}^n X_i X_i^T \right) \bar{R}^{-1/2} \\ &= \bar{R}^{-1/2} \bar{R} \bar{R}^{-1/2} = I, \end{aligned} \quad (12)$$

i.e., the mean covariance matrices of all subjects are equal to the identity matrix after alignment, and hence the distributions of the covariance matrices from different subjects are more similar. This is very desirable in TL.

图：EA 算法步骤


He 等人在论文中也验证了 EA 算法的性能，并在实验中选择了 CSP+LDA 与 EA+CSP+LDA 进行对比，以及 xDAWN+SVM 与 EA+xDAWN+SVM 进行对比。因此笔者也做了类似实验，具体结果将在下一节展示，EA 对于本数据集并没有显著提升。

2.2 基于散度的域适应

本模型旨以 CNN 作为 baseline，希望 CNN 隐层的特征分布对于源域和目标域有一定一致性，这样在源域训练的分类网络可以更好的迁移到目标域上。

具体来说，网络对 source 和 target domain 的数据一起训练，共享网络参数。source 数据的输出与 source label 进行监督训练，得到分类的 loss。而 target 数据的输出由于没有标注数据进行监督训练，因此要和 source 进行适应，计算分布差异损失。最终的目的是要将分类损失和分布差异损失共同优化到最小，即 source 的分类更精确，target 的输出与 source 的分布更相似。

有关分布差异损失，这里笔者选择了 MMD Loss^[3]、CORAL Loss^[4]以及自行设计的欧式距离损失。关于所期望一致的隐藏特征，笔者选用了 CNN 网络 VGG Block 3 的输出。见下图所示。



欧式距离损失：源域和目标域间每一对样本间欧式距离。

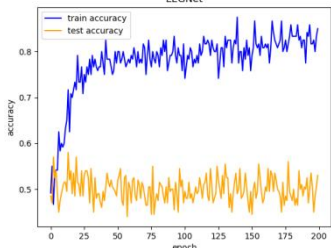
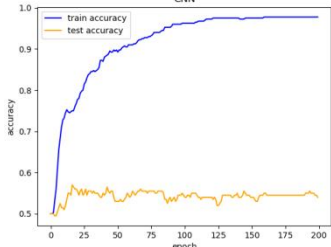
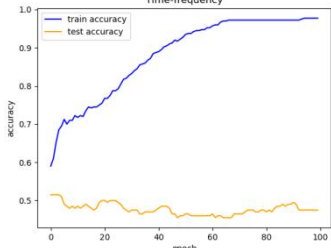
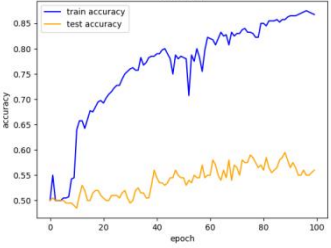
添加了域适应损失后，网络表现有提升，具体数据及实验将在第三节说明。

3 实验

3.1 实验设置

- 仅选用前 300 时间步的源数据。源数据时间步长度为 750，实验发现，选用靠后的时间步所蕴含的信息会使模型性能下降。因此选用前 300 个时间步。
- 以 S1, S2, S3 为训练集，S4 为测试集。与打乱数据集后以一定比例分割训练集、测试集相比，这种划分方法更能验证跨个体预测的表现。

3.2 基础模型实验结果

模型名称		训练集准确率	测试集准确率	结论	训练图像
EEGNet		≈ 1	≈ 0.5	不能提取有效特征	
CNN	以源数据作为输入	0.895	0.565	测试集准确度较稳定，可以提取特征，但是泛化能力较弱	
	以时频图作为输入	≈ 1	< 0.5	测试集正确率较稳定，但是数据均值小于等于0.5，不能提取有效特征	
LSTM		0.5	0.5	不收敛	-
CNN+LSTM		0.825	0.570	特征有意义，但是训练波动较大	
XGBoost	XGBoost	> 0.95	0.45~0.5	提取不到有用信息	-
	PCA+XGBoost	≈ 0.90	≈ 0.5	提取不到有用信息	-
特征提取器+分类器	CSP+LDA	≈ 0.65	< 0.5	提取不到有用信息	-
	xDAWN+SVM	1.000	0.500	提取不到有用信息	-

基础模型中，可用的模型有：CNN 以及 CNN+LSTM。

3.3 迁移学习实验结果

基于 3.2 中基础模型的实验结果，笔者选择了两种基础模型（CNN、特征提取+分类器）做为 baseline 用于探究迁移学习对结果的影响。

3.3.1 EA 实验

笔者将 EA 数据对齐方法分别与 CNN、CSP+LDA 及 xDAWN+SVM 结合，比较加入 EA 前后指标优劣。

● EA+CNN

使用了 EA 后，模型效果提升了五个点左右，可见 EA 在深度学习方法中有很大的作用。

模型	正确率
CNN	0.565
EA+CNN	0.620

● EA+CSP+LDA

对于 CSP+LDA 模型来说，使用 EA 后，效果仍然有提升。关于滤波器个数的选择，如右图所示，选择滤波器组数为 4 最合适。

模型	正确率
CSP+LDA	<0.5
EA+CSP+LDA	0.630




图 EA 以及滤波器个数对 CSP+LDA 模型的影响

● EA+xDAWN+SVM

加入 EA 后基本无改善。依然过拟合严重。

模型	正确率
xDAWN+SVM	0.500
EA+xDAWN+SVM	0.515




图 EA 以及滤波器个数对 xDAWN+SVM 模型的影响

3.3.2 基于散度的域适应实验

本实验的 baseline 分别采用了 CNN 和 EA+CNN 模型。依据选用的散度损失 (CORAL Loss, MMD Loss 以及 pair-wise 欧式距离损失)，相对应的，每种 baseline 分别有三种域适应模型 (CORAL, MMD, Eu Distance)。

用此模型对未知标签样本进行测试时，需要根据新的测试样本重新训练模型，因此不能根据现有验证集指标选择最优模型。根据在验证集所做实验，发现模型在 45 至 55 轮左右性能比较好而且表现稳定（如下图），因此**实际测试时，选用 45、50 和 55 轮模型做投票**，最终结果做为预测结果。

根据以上设定，在评价指标时，也依照上述方法进行。




图 EA CNN 域适应模型训练过程

可以看出在 45~55 轮表现较好且稳定

● 基于 EA CNN 模型的域适应

实验结果如下：

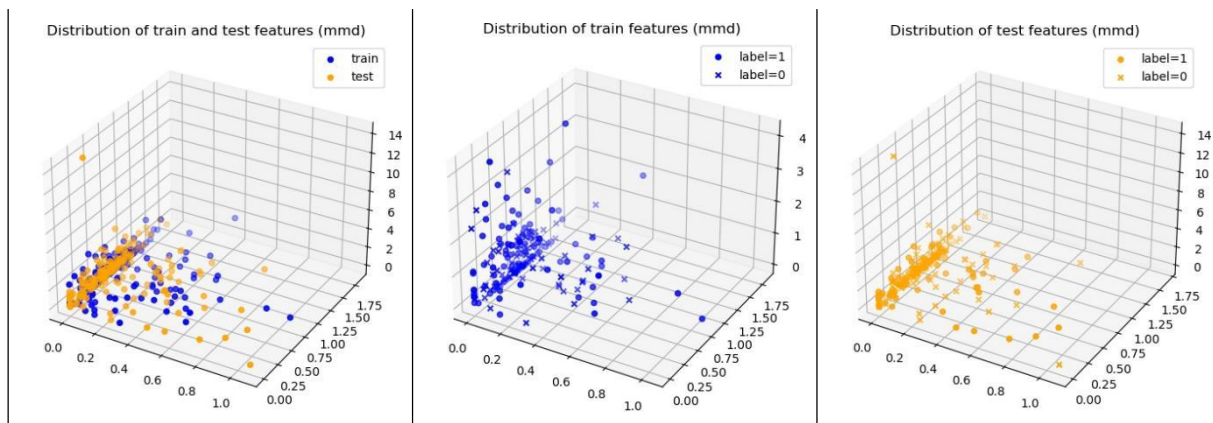
模型		正确率
Baseline	EA+CNN	0.620
域适应 CNN	EA+CNN+CORAL	0.620
	EA+CNN+MMD	0.630
	EA+CNN+Eu Distance	0.605
域适应 CNN 投票	-	0.605

可以看出，MMD 域适应的方法较于 baseline 有一个点的提升。

● 源域和目标域隐藏特征可视化



EA
CNN
MMD



可以看出，基于散度的域适应 CNN 方法比 CNN 表现更好，特征分布更相近。

4 结论

本课题笔者尝试了多种基本模型以及两种迁移学习方式。最终选择了性能最好且训练方便的 EA+CSP+LDA 模型进行测试。

基本模型中：CNN 与 CNN+LSTM 模型效果最好，分类正确率分别达到了 0.565 和 0.570。

迁移学习中：

- EA 方法：欧氏对齐方法使得 CNN、CSP+LDA 的性能提升，其中 EA+CSP+LDA 分类正确率达到 0.630。
- 基于散度的域适应方法：EA+CNN+MMD 较 EA+CNN 有提升，正确率达到了 0.630。

实验结果总结：

模型	正确率
基本模型	
CNN	0.565
CNN+LSTM	0.570
迁移学习模型	
EA+CNN	0.620
EA+CNN+CORAL	0.620
EA+CNN+MMD	0.630
EA+CNN+Eu Distance	0.605
EA+CSP+LDA	0.630

参考文献

- ^[1] Wu D, Xu Y, Lu B L. Transfer learning for EEG-based brain–computer interfaces: A review of progress made since 2016[J]. IEEE Transactions on Cognitive and Developmental Systems, 2020, 14(1): 4-19.
- ^[2] He H, Wu D. Transfer learning for brain–computer interfaces: A Euclidean space data alignment approach[J]. IEEE Transactions on Biomedical Engineering, 2019, 67(2): 399-410.
- ^[3] Long M, Zhu H, Wang J, et al. Unsupervised domain adaptation with residual transfer networks[J]. Advances in neural information processing systems, 2016, 29.
- ^[4] Sun B, Saenko K. Deep coral: Correlation alignment for deep domain adaptation[C]//European conference on computer vision. Springer, Cham, 2016: 443-450.